

重庆青少年心理健康项目

阶段汇报

五种客观测量的目的、结论与原因分析

报告区间：2026 年 9 月 7 日 – 9 月 10 日

一页纸结论

这四天里，我们把手上**全部五种客观测量**——脑电、近红外、面部视频、行为按键、眼动——都完整地试了一遍，并且第一次对脑电动用了深度学习。

主要结论：五种测量都没能超过“问三个问题”的效果。那三个问题是年龄、性别、年级。只用这三项建立的模型，判断水平已达 0.67（后文解释这个数字怎么读）。

但这句话如果只看一半，会得出错误的印象。有四点请导师特别注意：

- **测量本身是好的。**五种数据里都验证到了教科书上该出现的生理现象——脑电的 P300 波、大脑血流的正常反应、孩子看到笑脸会去看嘴巴、做错题之后反应变慢。数据、仪器、处理流程都没问题。
- **“低”是有具体原因的，而且原因各不相同。**有些是采集环节真的丢了数据（比如一台设备的按键从头到尾没记上），有些是实验设计本身不够（比如每种情绪只放了 12 张照片，导致指标根本测不准），有些是任务测的东西和情绪无关。第 3 节逐条列出。这些是可以改进的。
- **脑电深度模型最接近成功。**在放宽判断标准后，脑电有 35 个结果存活下来，是五种测量里最多的。第 4 节完整交代这批结果——包括它们为什么最终没被采信。
- **本阶段最重要的产出是一套判断规则。**四天里出现过三次“看起来成功了”的结果，全部被这套规则拦下。规则是在真实错误里一条条长出来的。

问题	回答
客观测量能诊断吗？	在本队列、按目前方法，不能超过年龄性别年级。
是数据本身没信息吗？	不是。同一套方法猜年龄能到 0.82、猜性别 0.77。
那为什么低？	采集缺陷、试次不足、设备与学校混淆、任务与情绪无关。见第 3 节。
有接近成功的吗？	有。脑电深度模型，见第 4 节。
下一步做什么？	见第 7 节，四个方向。

1 这个项目在问什么

1.1 任务

我们收集了三千多名中小学生的多种客观测量数据，想回答：**能不能不依赖问卷和访谈，只靠仪器测到的信号，判断一个孩子是否存在心理健康问题（有 / 无）。**

1.2 为什么“年龄性别年级”是一道必须跨过的门槛

这是理解整份报告的关键。

在我们这批孩子里，心理问题的出现率本身就与年龄、性别、年级相关——年级越高比例越高。所以哪怕完全不看仪器数据，只知道“这是一个初三的女生”，就已经能做出相当程度的猜测。

我们实测了这个水平：**只用年龄、性别、年级三项，达到 0.67。**

因此任何一种客观测量要证明自己有用，**光比瞎猜强是不够的**，必须证明：在已经知道年龄性别年级的前提下，再加上它，判断会更准。这个“额外提升”是全文的核心概念。

1.3 这些数字怎么读

数值	含义
0.50	完全等于抛硬币，没有任何判断能力
0.60	有一点点能力，但很弱
0.67	年龄性别年级三项达到的水平
0.80	相当不错
1.00	完美，永不出错

更直观的说法：**0.67 的意思是，随便挑一个有问题的孩子和一个没问题的孩子，模型有 67% 的把握把前者排在前面。**


2 五种测量的目的与结论

2.1 总览

下表每一行都是**在同一批孩子身上、用同一个模型**算出来的三个数：这个模态自己有多强、只用年龄性别年级有多强、以及**把两者合起来**有多强。

最后一列是本报告最关键的一个量——**把模态加进去之后，判断到底改善了多少**，方括号里是它的 95% 置信区间。

测量	人数	模态单独	只用人口学	人口学 + 模态	提升与	95% 区间
眼动	305	0.578	0.653	0.674	+0.021	[-0.048, +0.089]
行为按键	1412	0.558	0.590	0.608	+0.018	[-0.005, +0.040]
近红外	524	0.547	0.579	0.592	+0.013	[-0.041, +0.067]
脑电（深度）	1820	0.534	0.602	0.604	+0.002	[-0.006, +0.008]
面部视频	3381	0.617	0.669	0.666	-0.002	[-0.017, +0.011]
脑电（特征）	1820	0.527	0.604	0.571	-0.033	[-0.059, -0.006]



图里有两件事值得看。

第一，每一根蓝条都是三根里最短的。任何一个模态单独拿出来，都不如年龄性别年级。但**短的原因各不相同**，这正是第 3 节要讲的。

第二，绿条和橙条几乎一样长。把模态加进去之后，成绩基本没动——这就是全部结论所在。

2.2 为什么“绿条比橙条长一点”还不够

看表格最后一列：**六组里有四组的提升是正的**（眼动 +0.021、行为 +0.018、近红外 +0.013、深度脑电 +0.002）。这很容易让人得出“那这些模态还是有用的”这一结论。

但这个结论下不得，原因在方括号里。

方括号里是**置信区间**，表示这个差值真实可能落在什么范围内。判断标准只有一条：**区间必须整个在零的一侧**。

看眼动那一行：+0.021 听上去不错，但区间是 [-0.048, +0.089]——**从“明显有害”一直横跨到“明显有用”**。305 个孩子的数据量，分辨不出这 0.021 是真实效应还是随机波动。

打个比方：抛 10 次硬币出现 6 次正面，数字确实大于 5，但没人会因此断定硬币有偏。要下这个判断，得抛几百次。**上表六行，没有任何一行的区间排除了零**（唯一排除零的是最后一行，而它在零的负侧）。

这正是第 5 节要讲的那三次假阳性的成因——当时就是只看了点估计，没看区间。

最后一行的负号不代表“有害”

脑电传统特征那一行是显著变差的，这一点需要单独解释，否则容易被误读。

原因是“**稀释**”：模型要同时消化 3 列人口学变量和 321 列脑电特征，当后者不含有用信息时，前者的作用会被摊薄。这是分析方法的性质，**不是脑电把结果搞砸了**。

证据是：Goal 3 改用了一种不会稀释的组合方式（先各自算出预测分数再合并），同样的比较做了 56 次，**结果是 0 次显著正、0 次显著负**，全部落在 -0.008 到 +0.005 之间。稀释一消失，负号也就消失了。

所以这里的负号意思是“没有信号”，不是“起了反作用”。

2.3 脑电

目的：孩子戴电极帽完成“听声音数目标音”的任务 (Oddball)，检验大脑对刺激的电反应能否区分有无心理问题。

做了什么：此前的分析有一个严重错误——程序只保留了目标音的反应，把作为对照的标准音全丢了，等于只有一半数据。这次从原始记录重新恢复了完整的两种条件，看到了非常漂亮的 P300 波，在 88% 的孩子身上都存在。随后第一次对它使用深度学习。

结论：没有额外提升。在已知年龄性别年级基础上加入脑电深度模型，提升 **+0.0016**，几乎为零。但脑电是五种测量里最接近成功的一种，详见第 4 节。

一个关键对照：用完全相同的程序、孩子、数据，只换要猜的目标：

让同一套程序去猜	成绩
孩子的年龄	0.82
孩子的性别	0.77
这一声是目标音还是标准音	0.82
孩子有没有心理问题	0.55

程序显然有学习能力。学不到的是“心理状态”。

2.4 近红外

目的：近红外测大脑皮层血流变化，反映脑区在完成任务时的活跃程度。孩子做了五个任务（静息、词语流畅、记忆、听声音、赌博游戏）。

做了什么：此前卡在技术错误上——读取程序只看文件头，没真正读进数据，导致所有任务反应被判为“不可用”。这次重写了读取程序，五个任务在两台设备上全部解

锁，并验证到了正常的血流反应（做词语流畅任务时左脑更活跃，符合语言功能的常识）。

结论：没有额外提升，而且是五种里最彻底的——即便把判断标准大幅放宽，依然一条都没通过。

2.5 面部视频

目的：孩子观看情绪影片时被摄像头录下，检验面部表情能否反映心理状态。

做了什么：此前是在 11 分钟录像里均匀取 16 帧，但这 11 分钟混杂了看影片、朗读、答题等完全不同的环节，取出来的画面大部分只反映“孩子长什么样、房间什么样”。这次按实验记录切成了对应三段情绪影片的片段，并计算**同一个孩子看负性影片与正性影片时的差异**。

结论：没有额外提升。但这里有**本项目唯一真正站得住的正面发现**。

我们设了一个“背景对照”：把画面里的人脸挖掉，只用背景预测。如果模型靠背景就能预测，说明它学的是学校和房间，不是孩子。结果：**面部的“负性减正性”差异显著赢过了自己的背景对照，最强 +0.115**。

这个比较有力，是因为同一个孩子的长相、房间、摄像头、学校在这个减法里**自动抵消了**。所以这部分信号确实来自表情本身。**只是它仍赢不过年龄性别年级**。

2.6 行为按键

目的：孩子做任务时的每次按键（对错、快慢）都被记录，此前从没人读过。检验反应速度、注意力维持、做错后的调整能否反映心理状态。

做了什么：第一次系统读取这些日志，提取工作记忆表现、反应时间及波动、错误后减速、赌博任务的输赢反应等。

结论：没有额外提升，但**行为指标本身非常健康**——两台设备上的孩子都表现出教科书式规律：做错一题后下一题会慢 100 毫秒左右（76% 的孩子如此），第二组比第一组更快。这些规律在两批完全不同的孩子身上独立重现。

2.7 眼动

目的：孩子做了三个任务：自由观看情绪面孔、按指令看向 / 看开目标、用眼睛追踪移动的点。心理学文献普遍认为抑郁的人看负性面孔更久，我们要检验这一点。

做了什么：先系统查阅近年文献、写下方法和预期，然后才开始分析。过程中修正了四个技术问题，其中一个很关键：**三台设备记录的视线位置都系统性偏低**，不校正的话“人看脸时先看眼睛”这条铁律会在两台设备上反号。

结论：没有额外提升。三台不同设备、三种采样率、三批几乎不重合的孩子，结论完全一致。

2.8 一个来自医院的独立验证

眼动分析全部完成之后，医院才补送来眼动范式的原始说明文档。这是难得的检验机会——我们此前所有参数都是从记录数据里反推的，没有任何文档参照。

结果：文档逐项确认了我们反推的参数。包括面孔呈现 4 秒、每种情绪 12 张、扫视任务 8 个试次、追踪任务快慢两档恰好是二倍频关系。其中两个参数是我们分析过程中因为“结果不合常理”而主动修正过的，文档证明我们改对了。

3 为什么都低：逐条原因

这是本报告最有实际价值的一节。“没有超过人口学”是一个结果，但**原因不止一个，而且大部分是可以改进的**。我们把查到的原因分成四类。

3.1 第一类：采集环节真的丢了数据

这些是硬性的数据损失，不是分析方法的问题。

问题	后果
必可明设备的“听声音”任务 从头到尾没有采集到按键	640 名孩子里 549 名的按键记录完全是空的，厂商自己的样例记录也是空的。整个单元只能作废。
益瑞德设备的赌博任务 反应窗口设成 1 秒，而门在屏幕上停留 4.5 秒	只有 38% 的选择被记录下来（另一台设备是 98%）。可用的“赢了继续 / 输了改选”配对从 24 组降到 6 组。
50 名孩子运行的记忆任务版本 里根本没有重复出现的图片	无法计算“认出重复”这一核心指标，只能排除。
必可明设备的词语流畅任务 没有记录任何时间标记	无法确定任务何时开始，该任务只能作参考。

建议：前两项应尽快反馈给设备方与实验设计方。

3.2 第二类：实验设计本身的试次不够

这一类最值得重视，因为它意味着**有些指标从原理上就测不准，再多的分析也救不回来**。

最典型的例子是眼动的情绪面孔任务。这个任务是整个眼动分析的理论核心——文献认为抑郁的人看负性面孔更久。但这个范式**每种情绪只放了 12 张照片**。

我们直接检验了这个指标测得准不准：把每个孩子的试次分成单双数两半，看两半算出来的结果是否一致。

指标类型	一致性	三台设备都可靠的指标数
看某类面孔的绝对时长	0.70（良好）	53 个
负性减中性的差值	-0.05（等于没有）	0 个

原因是纯粹的算术：两个各由 12 张照片估出来的数相减，误差全部留下，而真实差异反而抵消掉了。三台设备上独立重现了同一现象。

这一点必须说清楚：我们的阴性结果说明的是“这个实验设计测不出情绪注意偏向”，而不是“情绪注意偏向不存在”。这是关于仪器的结论，不是关于疾病的结论。

同类问题还有两处：

- **扫视任务每组只有 8 个试次。**错误率的最小分辨单位因此是 $1/8 = 0.125$ ，而文献中常用的同类任务有 40 到 100 个试次。
- **面部的“负性减正性”差异，幅度只有原始画面信息的 17%。**减法去掉了长相和房间（这是好事），但剩下的真实表情信号本身就很微弱。

3.3 第三类：设备与学校分不开

近红外的两台设备，几乎是在两批完全不同的孩子身上使用的——1527 人对 1022 人，重合的只有 1 人。眼动的三台设备也是各自负责不同的学校。

这带来一个无法在事后修复的问题：“**设备差异**”和“**学校差异**”完全混在一起，无法分辨一个信号到底来自仪器还是来自学校。因此两台设备的数据不能合并分析，样本量被硬生生切成两半。

我们也确认了学校本身就是一个很强的预测因素——**光凭孩子来自哪所学校，预测水平就能到 0.67**，和年龄性别年级相当。这说明不同学校的孩子患病比例差别很大，任何分析都必须先把这个因素排除掉，否则会把“学校差异”误认成“生理差异”。

建议：后续如需扩展数据收集，应让每台设备在每所学校都采集一部分，而不是一台设备包一所学校。

3.4 第四类：任务测的东西可能和情绪无关

- **脑电用的 Oddball 任务，测的是注意力和对新异刺激的反应**，本身不是情绪任务。它能非常可靠地反映“这个人有没有在专心听”，但未必反映心情。
- **眼动的追踪任务，其原始文献针对的是精神分裂症**，不是抑郁。这套范式是从另一个临床问题上借用过来的。
- **诊断标签本身可能过于笼统。**目前把抑郁、焦虑、高风险合并成了“有问题”这一类。不同问题的生理表现很可能不同，合并之后互相抵消。

3.5 第五类：样本量与方法层面的限制

- 部分队列偏小：近红外的听声音任务只有 524 人，眼动各单元 247 到 336 人，行为学的三任务交集只有 342 人。样本越小，结果越不稳定（第 5 节会说明这带来的具体危害）。
- 深度模型的成绩在不同随机初始值下波动可达 0.05，而我们要检测的效应只有 0.005 量级。**这意味着非常微小的效应在当前条件下无法被可靠检出。**
- 用于最终验证的那批孩子（900 人）在项目早期已被使用过，因此严格意义上的最终验证需要一批全新的孩子。

4 最接近成功的一次：脑电深度模型

前面说“五种都没超过”，但并非五种都一样地没超过。**脑电明显比其他四种更接近**。这一节完整交代这批结果，包括我们最终没有采信它的理由。

4.1 放宽标准后，脑电存活最多

我们的判断规则一共九条。为了确认这些规则不是“过于严格以至于埋没了真信号”，我们做了一次压力测试：**去掉其中六条，重新检查此前全部 878 次比较**。

测量	比较次数	放宽后存活	再加一条折数要求
脑电	302	35	20
面部视频	66	12	10
眼动	288	0	0
行为按键	84	0	0
近红外	138	0	0

脑电存活 35 个，是五种测量里最多的，也是唯一一个在深度模型上还有东西剩下的。眼动、行为、近红外全部归零。面部存活的 12 个来自已被取代的旧分析。

这 35 个结果里，最强的一批提升在 **+0.028 到 +0.031**，统计区间都不含零。如果只看这一页，结论会是“脑电深度模型有效”。

4.2 但它们集中在一个随机种子上

深度学习每次训练都要从一个随机初始值开始。我们跑了三个不同的初始值（称为“种子”）。这 35 个结果的分布是：

位置	存活数
种子 2，分组验证	28
种子 0，标准验证	6
种子 0，分组验证	1
种子 1	0

28 个挤在同一格里。把那一格拆开看，情况就清楚了：

种子	人口学	脑电深度	人口学 + 脑电	提升
0	0.5814	0.5499	0.5873	+0.006
1	0.6013	0.5597	0.5812	-0.020
2	0.5574	0.5234	0.5865	+0.029
三次平均	0.5909	0.5475	0.5878	-0.003

请注意第四列：“**人口学 + 脑电**”这一列三次几乎不动（0.5873、0.5812、0.5865，相差不到 0.006）。真正在跳的是第二列“**人口学**”自己，从 0.6013 掉到 0.5574，跳了 0.044。而且在种子 2 那一次，**脑电自己的成绩反而是三次里最差的**（0.5234）。

4.3 结论

所以种子 2 的那个“+0.029 提升”，**不是脑电变强了，是被比较的对手那一次没发挥好**。加上脑电之后的最终成绩，三次都是 0.58 左右，没有任何变化。

三次平均之后，提升是 **-0.003**——也就是没有。

我们最终没有采信这批结果。但它们值得完整记录下来，理由有三个：

- 这是本项目中**客观测量最接近成功的一次**，如实记录比只报告结论更诚实；
- 它清楚地展示了一个重要的方法学教训：**在样本不大的时候，看似漂亮的“提升”可能完全来自对手的波动**；
- 如果未来要重新检验脑电，**应当从多种子平均开始**，而不是从单次训练的结果开始。

5 三次“看起来成功了”：本阶段最重要的产出

上一节的脑电种子问题不是孤例。这四天里，有三次我们的分析给出了阳性结果，如果直接采信，报告会写成“行为学、眼动、脑电深度模型分别发现了独立信号”。

三次全是假的，三次全被拦下了。

阶段	涉及	真相
行为学	8 个结果	它们赢过的“年龄性别年级”基线，在那一小批孩子（342 人）里 本身低于抛硬币 。不是行为学变强了，是对手垮了。
眼动	18 个结果	完全相同的机制，全部出现在同一台设备的小样本里。
脑电深度	7 个结果	深度模型“赢过”传统特征——而传统特征在那个条件下也低于抛硬币。

5.1 为什么会这样

打个比方：考试比的是两个学生的名次。如果对手因为生病考了零分，你赢了他，并不说明你考得好。

样本量小的时候，“年龄性别年级”这个对手会不稳定，有时会发挥失常到比瞎猜还差。这时任何一个平庸的模型都能“赢”它，而统计检验会一本正经地告诉你这个胜利是显著的。

5.2 我们做了什么

第一次（行为学）发现后，我们做了三项独立验证确认它是假的。最有说服力的一项是：**把孩子的诊断标签随机打乱 100 次重跑**——在完全没有真实关联的情况下，仍有约六分之一的次数能重现出同样大的“提升”。

然后给判断规则加了一条：**一个结果要被采信，它赢过的对手必须自己先站得住（高于抛硬币）。**

这条规则随后拦下了眼动的 18 个和脑电的 7 个。**如果没有它，这份报告会包含三个错误的阳性发现。**

6 我们能确定什么，不能确定什么

6.1 可以确定的

- 在**这一批孩子**身上、用**目前这套方法**，五种客观测量都不能超过年龄性别年级。
- 这个结论不是数据质量或程序错误造成的——五种数据的生理效度都独立验证过。
- 面部表情中确实存在超出“房间和长相”的真实信息，只是不足以超过人口学。
- 眼动范式中的“情绪注意偏向”指标，在当前设计下测不准。

6.2 不能由此推断的

- **不能说“心理问题没有客观生物标记”。**我们检验的是特定的几种测量、特定的分析方法、特定的一批孩子，而且其中若干条已知存在采集或设计缺陷。
- **不能说这些数据没有价值。**它们能很好地预测年龄和性别，在其他研究问题上仍然有用。
- **不能说“再多试几种方法就一定能成”。**我们已经用了从传统特征到深度学习的多种方法。

7 下一步的四个方向

1. **反馈已发现的采集缺陷。**把赌博任务响应窗口设置、必可明按键未采集这两个问题反馈给设备方与实验设计方，避免在后续批次里重复发生。
2. **如果还有新一轮采集，修改实验设计。**情绪面孔从每种 12 张增加到 40 张以上，扫视任务从 8 个试次增加到 40 个以上，让每台设备在每所学校都采一部分。这三项改动直接针对第 3 节查出的原因。
3. **重新考虑研究问题的定义。**目前的“有 / 无心理问题”把抑郁、焦虑、高风险合并成一类，可能过于笼统。换成症状严重程度的连续评分，或某一类特定症状，客观测量可能有更好表现。建议与医院方共同讨论。
4. **把已验证的测量用于其他问题。**这些数据在年龄和性别上的预测能力很强（0.77–0.82）。发育轨迹、认知能力发展等方向可能比疾病分类更适合这批数据。

本报告为面向非技术读者的汇报版本，略去了方法细节、完整结果表和统计过程。逐项数据、方法说明与全部结果表见 `reports/latex/technical/` 下的技术版报告（27 页），以及项目内的 `PROGRESS.md` 与 `reports/` 各阶段报告。本报告中的每一个数字均来自项目结果表，未作估算。