

重庆青少年心理健康项目

阶段汇报

五种客观测量的目的、结论与原因分析

报告区间：2026 年 9 月 7 日 – 9 月 10 日

一页纸结论

这四天里，我们把手上**全部五种客观测量**——脑电、近红外、面部视频、行为按键、眼动——都完整地试了一遍，并且第一次对脑电动用了深度学习。

主要结论：五种测量都没能超过“问三个问题”的效果。那三个问题是年龄、性别、年级。只用这三项建立的模型，判断水平已达 0.67（后文解释这个数字怎么读）。

但这句话如果只看一半，会得出错误的印象。有四点请导师特别注意：

- **测量本身是好的。**五种数据里都验证到了教科书上该出现的生理现象——脑电的 P300 波、大脑血流的正常反应、孩子看到笑脸会去看嘴巴、做错题之后反应变慢。数据、仪器、处理流程都没问题。
- **“低”是有具体原因的，而且原因各不相同。**有些是采集环节真的丢了数据（比如一台设备的按键从头到尾没记上），有些是实验设计本身不够（比如每种情绪只放了 12 张照片，导致指标根本测不准），有些是任务测的东西和情绪无关。第 3 节逐条列出。这些是可以改进的。
- **脑电深度模型最接近成功。**在放宽判断标准后，脑电有 35 个结果存活下来，是五种测量里最多的。第 4 节完整交代这批结果——包括它们为什么最终没被采信。
- **本阶段最重要的产出是一套判断规则。**四天里出现过三次“看起来成功了”的结果，全部被这套规则拦下。规则是在真实错误里一条条长出来的。

问题	回答
客观测量能诊断吗？	在本队列、按目前方法，不能超过年龄性别年级。
是数据本身没信息吗？	不是。同一套方法猜年龄能到 0.82、猜性别 0.77。
那为什么低？	采集缺陷、试次不足、设备与学校混淆、任务与情绪无关。见第 3 节。
有接近成功的吗？	有。脑电深度模型，见第 4 节。
下一步做什么？	见第 7 节，四个方向。

1 这个项目在问什么

1.1 任务

我们收集了三千多名中小学生的多种客观测量数据，想回答：**能不能不依赖问卷和访谈，只靠仪器测到的信号，判断一个孩子是否存在心理健康问题（有 / 无）。**

1.2 为什么“年龄性别年级”是一道必须跨过的门槛

这是理解整份报告的关键。

在我们这批孩子里，心理问题的出现率本身就与年龄、性别、年级相关——年级越高比例越高。所以哪怕完全不看仪器数据，只知道“这是一个初三的女生”，就已经能做出相当程度的猜测。

我们实测了这个水平：**只用年龄、性别、年级三项，达到 0.67。**

因此任何一种客观测量要证明自己有用，**光比瞎猜强是不够的**，必须证明：在已经知道年龄性别年级的前提下，再加上它，判断会更准。这个“额外提升”是全文的核心概念。

1.3 这些数字怎么读

数值	含义
0.50	完全等于抛硬币，没有任何判断能力
0.60	有一点点能力，但很弱
0.67	年龄性别年级三项达到的水平
0.80	相当不错
1.00	完美，永不出错


更直观的说法：**0.67 的意思是，随便挑一个有问题的孩子和一个没问题的孩子，模型有 67% 的把握把前者排在前面。**

2 五种测量的目的与结论

2.1 总览

下表每一行都是**在同一批孩子身上、用同一套方法**做的对比。

测量	人数	测量单独	年龄性别年级	谁更强
脑电（传统特征）	1820	0.540	0.604	人口学
脑电（深度学习）	1820	0.545	0.604	人口学
近红外	524	0.566	0.579	人口学
面部视频	3381	0.624	0.672	人口学
行为按键	1412	0.558	0.596	人口学
眼动	305	0.646	0.678	人口学



每一根蓝条都比它对应的橙条短。但短的原因各不相同，这正是第 3 节要讲的。

2.2 真正做决定的那张表

上面那张表回答的是“这个模态自己有多强”。但项目真正用来下结论的，是另一个比较：**在已经知道年龄性别年级的基础上，再加上这个模态，判断会不会更准。**

下表每一行都是**同一个模型**在加与不加该模态时的对比。（因此“只用人口学”一系列的数值与上表略有出入——上表取的是各自最好的模型，这里必须取同一个。）

测量	人数	只用人口学	加上该模态	差值与 95% 区间
眼动	305	0.6525	0.6737	+0.021 [-0.048, +0.089]
行为按键	1412	0.5903	0.6084	+0.018 [-0.005, +0.040]
近红外	524	0.5792	0.5919	+0.013 [-0.041, +0.067]
脑电（深度）	1820	0.6023	0.6039	+0.002 [-0.006, +0.008]
面部视频	3381	0.6687	0.6663	-0.002 [-0.017, +0.011]
脑电（特征）	1820	0.6037	0.5710	-0.033 [-0.059, -0.006]

六组里有四组的数字确实变高了。这很容易让人得出“那这些模态还是有用的”这一结论。但这个结论下不得，原因在最后一列。

为什么“变高了”还不够

方括号里是**置信区间**，表示这个差值真实可能落在什么范围内。判断标准只有一条：**区间必须整个在零的一侧**。

看眼动那一行： $+0.021$ 听上去不错，但区间是 $[-0.048, +0.089]$ ——从“**明显有害**”一直横跨到“**明显有用**”。305 个孩子的数据量，分辨不出这 0.021 是真实效应还是随机波动。

打个比方：抛 10 次硬币出现 6 次正面，数字确实大于 5，但没人会因此断定硬币有偏。要下这个判断，得抛几百次。**上表六行，没有任何一行的区间排除了零**（唯一排除零的是最后一行，而它在零的负侧）。

这正是第 5 节要讲的那三次假阳性的成因——当时就是只看了点估计，没看区间。

最后一行的负号不代表“有害”

脑电传统特征那一行是显著变差的，这一点需要单独解释，否则容易被误读。

原因是“**稀释**”：模型要同时消化 3 列人口学变量和 321 列脑电特征，当后者不含有用信息时，前者的作用会被摊薄。这是分析方法的性质，**不是脑电把结果搞砸了**。

证据是：Goal 3 改用了一种不会稀释的组合方式（先各自算出预测分数再合并），同样的比较做了 56 次，**结果是 0 次显著正、0 次显著负**，全部落在 -0.008 到 $+0.005$ 之间。稀释一消失，负号也就消失了。

所以这里的负号意思是“没有信号”，不是“起了反作用”。

2.3 脑电

目的：孩子戴电极帽完成“听声音数目标音”的任务 (Oddball)，检验大脑对刺激的电反应能否区分有无心理问题。

做了什么：此前的分析有一个严重错误——程序只保留了目标音的反应，把作为对照的标准音全丢了，等于只有一半数据。这次从原始记录重新恢复了完整的两种条件，看到了非常漂亮的 P300 波，在 88% 的孩子身上都存在。随后第一次对它使用深度学习。

结论：没有额外提升。在已知年龄性别年级基础上加入脑电深度模型，提升 $+0.0016$ ，几乎为零。但脑电是五种测量里最接近成功的一种，详见第 4 节。

一个关键对照：用完全相同的程序、孩子、数据，只换要猜的目标：

让同一套程序去猜	成绩
孩子的年龄	0.82
孩子的性别	0.77
这一声是目标音还是标准音	0.82
孩子有没有心理问题	0.55

程序显然有学习能力。学不到的是“心理状态”。

2.4 近红外

目的：近红外测大脑皮层血流变化，反映脑区在完成任务时的活跃程度。孩子做了五个任务（静息、词语流畅、记忆、听声音、赌博游戏）。

做了什么：此前卡在技术错误上——读取程序只看文件头，没真正读进数据，导致所有任务反应被判为“不可用”。这次重写了读取程序，五个任务在两台设备上全部解锁，并验证到了正常的血流反应（做词语流畅任务时左脑更活跃，符合语言功能的常识）。

结论：没有额外提升，而且是五种里最彻底的——即便把判断标准大幅放宽，依然一条都没通过。

2.5 面部视频

目的：孩子观看情绪影片时被摄像头录下，检验面部表情能否反映心理状态。

做了什么：此前是在 11 分钟录像里均匀取 16 帧，但这 11 分钟混杂了看影片、朗读、答题等完全不同的环节，取出来的画面大部分只反映“孩子长什么样、房间什么样”。这次按实验记录切成了对应三段情绪影片的片段，并计算**同一个孩子看负性影片与正性影片时的差异**。

结论：没有额外提升。但这里有**本项目唯一真正站得住的正面发现**。

我们设了一个“背景对照”：把画面里的人脸挖掉，只用背景预测。如果模型靠背景就能预测，说明它学的是学校和房间，不是孩子。结果：**面部的“负性减正性”差异显著赢过了自己的背景对照，最强 +0.115**。

这个比较有力，是因为同一个孩子的长相、房间、摄像头、学校在这个减法里**自动抵消了**。所以这部分信号确实来自表情本身。**只是它仍赢不过年龄性别年级**。

2.6 行为按键

目的：孩子做任务时的每次按键（对错、快慢）都被记录，此前从没人读过。检验反应速度、注意力维持、做错后的调整能否反映心理状态。

做了什么：第一次系统读取这些日志，提取工作记忆表现、反应时间及波动、错误后减速、赌博任务的输赢反应等。

结论：没有额外提升，但**行为指标本身非常健康**——两台设备上的孩子都表现出教科书式规律：做错一题后下一题会慢 100 毫秒左右（76% 的孩子如此），第二组比第一组更快。这些规律在两批完全不同的孩子身上独立重现。

2.7 眼动

目的：孩子做了三个任务：自由观看情绪面孔、按指令看向 / 看开目标、用眼睛追踪移动的点。心理学文献普遍认为抑郁的人看负性面孔更久，我们要检验这一点。

做了什么：先系统查阅近年文献、写下方法和预期，然后才开始分析。过程中修正了四个技术问题，其中一个很关键：**三台设备记录的视线位置都系统性偏低**，不校正的话“人看脸时先看眼睛”这条铁律会在两台设备上反号。

结论：没有额外提升。三台不同设备、三种采样率、三批几乎不重合的孩子，结论完全一致。

2.8 一个来自医院的独立验证

眼动分析全部完成之后，医院才补送来眼动范式的原始说明文档。这是难得的检验机会——我们此前所有参数都是从记录数据里反推的，没有任何文档参照。

结果：文档逐项确认了我们反推的参数。包括面孔呈现 4 秒、每种情绪 12 张、扫视任务 8 个试次、追踪任务快慢两档恰好是二倍频关系。其中两个参数是我们分析过程中因为“结果不合常理”而主动修正过的，文档证明我们改对了。

3 为什么都低：逐条原因

这是本报告最有实际价值的一节。“没有超过人口学”是一个结果，但**原因不止一个，而且大部分是可以改进的**。我们把查到的原因分成四类。

3.1 第一类：采集环节真的丢了数据

这些是硬性的数据损失，不是分析方法的问题。

问题	后果
必可明设备的“听声音”任务 从头到尾没有采集到按键	640 名孩子里 549 名的按键记录完全是空的，厂商自己的样例记录也是空的。整个单元只能作废。
益瑞德设备的赌博任务 反应窗口设成 1 秒，而门在屏幕上停留 4.5 秒	只有 38% 的选择被记录下来（另一台设备是 98%）。可用的“赢了继续 / 输了改选”配对从 24 组降到 6 组。
50 名孩子运行的记忆任务版本 里根本没有重复出现的图片	无法计算“认出重复”这一核心指标，只能排除。
必可明设备的词语流畅任务 没有记录任何时间标记	无法确定任务何时开始，该任务只能作参考。
研究方案提到的 第三台眼动设备，数据一条都没有交付	少了一整批孩子的眼动数据。

建议：前两项应尽快反馈给设备方与实验设计方；最后一项建议向医院确认那批数据是否存在。

3.2 第二类：实验设计本身的试次不够

这一类最值得重视，因为它意味着**有些指标从原理上就测不准，再多的分析也救不回来**。

最典型的例子是眼动的情绪面孔任务。这个任务是整个眼动分析的理论核心——文献认为抑郁的人看负性面孔更久。但这个范式**每种情绪只放了 12 张照片**。

我们直接检验了这个指标测得准不准：把每个孩子的试次分成单双数两半，看两半算出来的结果是否一致。

指标类型	一致性	三台设备都可靠的指标数
看某类面孔的绝对时长	0.70（良好）	53 个
负性减中性的差值	-0.05（等于没有）	0 个

原因是纯粹的算术：两个各由 12 张照片估出来的数相减，误差全部留下，而真实差异反而抵消掉了。三台设备上独立重现了同一现象。

这一点必须说清楚：我们的阴性结果说明的是“这个实验设计测不出情绪注意偏向”，而不是“情绪注意偏向不存在”。这是关于仪器的结论，不是关于疾病的结论。

同类问题还有两处：

- **扫视任务每组只有 8 个试次**。错误率的最小分辨单位因此是 $1/8 = 0.125$ ，而文献中常用的同类任务有 40 到 100 个试次。
- **面部的“负性减正性”差异，幅度只有原始画面信息的 17%**。减法去掉了长相和房间（这是好事），但剩下的真实表情信号本身就很微弱。

3.3 第三类：设备与学校分不开

近红外的两台设备，几乎是在两批完全不同的孩子身上使用的——1527 人对 1022 人，重合的只有 1 人。眼动的三台设备也是各自负责不同的学校。

这带来一个无法在事后修复的问题：“**设备差异**”和“**学校差异**”完全混在一起，无法分辨一个信号到底来自仪器还是来自学校。因此两台设备的数据不能合并分析，样本量被硬生生切成两半。

我们也确认了学校本身就是一个很强的预测因素——**光凭孩子来自哪所学校，预测水平就能到 0.67**，和年龄性别年级相当。这说明不同学校的孩子患病比例差别很大，任何分析都必须先把这个因素排除掉，否则会把“学校差异”误认成“生理差异”。

建议：后续如需扩展数据收集，应让每台设备在每所学校都采集一部分，而不是一台设备包一所学校。

3.4 第四类：任务测的东西可能和情绪无关

- **脑电用的 Oddball 任务，测的是注意力和对新异刺激的反应**，本身不是情绪任务。它能非常可靠地反映“这个人有没有在专心听”，但未必反映心情。
- **眼动的追踪任务，其原始文献针对的是精神分裂症，不是抑郁**。这套范式是从另一个临床问题上借用过来的。
- **诊断标签本身可能过于笼统**。目前把抑郁、焦虑、高风险合并成了“有问题”这一类。不同问题的生理表现很可能不同，合并之后互相抵消。

3.5 第五类：样本量与方法层面的限制

- **部分队列偏小**：近红外的听声音任务只有 524 人，眼动各单元 247 到 336 人，行为学的三任务交集只有 342 人。样本越小，结果越不稳定（第 5 节会说明这带来的具体危害）。
- **深度模型的成绩在不同随机初始值下波动可达 0.05**，而我们要检测的效应只有 0.005 量级。**这意味着非常微小的效应在当前条件下无法被可靠检出。**
- **用于最终验证的那批孩子（900 人）在项目早期已被使用过**，因此严格意义上的最终验证需要一批全新的孩子。

4 最接近成功的一次：脑电深度模型

前面说“五种都没超过”，但并非五种都一样地没超过。**脑电明显比其他四种更接近**。这一节完整交代这批结果，包括我们最终没有采信它的理由。

4.1 放宽标准后，脑电存活最多

我们的判断规则一共九条。为了确认这些规则不是“过于严格以至于埋没了真信号”，我们做了一次压力测试：**去掉其中六条，重新检查此前全部 878 次比较**。

测量	比较次数	放宽后存活	再加一条折数要求
脑电	302	35	20
面部视频	66	12	10
眼动	288	0	0
行为按键	84	0	0
近红外	138	0	0

脑电存活 35 个，是五种测量里最多的，也是唯一一个在深度模型上还有东西剩下的。眼动、行为、近红外全部归零。面部存活的 12 个来自已被取代的旧分析。

这 35 个结果里，最强的一批提升在 **+0.028 到 +0.031**，统计区间都不含零。如果只看这一页，结论会是“脑电深度模型有效”。

4.2 但它们集中在一个随机种子上

深度学习每次训练都要从一个随机初始值开始。我们跑了三个不同的初始值（称为“种子”）。这 35 个结果的分布是：

位置	存活数
种子 2，分组验证	28
种子 0，标准验证	6
种子 0，分组验证	1
种子 1	0

28 个挤在同一格里。把那一格拆开看，情况就清楚了：

种子	人口学	脑电深度	人口学 + 脑电	提升
0	0.5814	0.5499	0.5873	+0.006
1	0.6013	0.5597	0.5812	-0.020
2	0.5574	0.5234	0.5865	+0.029
三次平均	0.5909	0.5475	0.5878	-0.003

请注意第四列：“**人口学 + 脑电**”这一列三次几乎不动（0.5873、0.5812、0.5865，相差不到 0.006）。真正在跳的是第二列“**人口学**”自己，从 0.6013 掉到 0.5574，跳了 0.044。而且在种子 2 那一次，**脑电自己的成绩反而是三次里最差的**（0.5234）。

4.3 结论

所以种子 2 的那个“+0.029 提升”，**不是脑电变强了，是被比较的对手那一次没发挥好**。加上脑电之后的最终成绩，三次都是 0.58 左右，没有任何变化。

三次平均之后，提升是 **-0.003**——也就是没有。

我们最终没有采信这批结果。但它们值得完整记录下来，理由有三个：

- 这是本项目中**客观测量最接近成功的一次**，如实记录比只报告结论更诚实；
- 它清楚地展示了一个重要的方法学教训：**在样本不大的时候，看似漂亮的“提升”可能完全来自对手的波动**；
- 如果未来要重新检验脑电，**应当从多种子平均开始**，而不是从单次训练的结果开始。

5 三次“看起来成功了”：本阶段最重要的产出

上一节的脑电种子问题不是孤例。这四天里，有三次我们的分析给出了阳性结果，如果直接采信，报告会写成“行为学、眼动、脑电深度模型分别发现了独立信号”。

三次全是假的，三次全被拦下了。

阶段	涉及	真相
行为学	8 个结果	它们赢过的“年龄性别年级”基线，在那一小批孩子（342 人）里 本身低于抛硬币 。不是行为学变强了，是对手垮了。
眼动	18 个结果	完全相同的机制，全部出现在同一台设备的小样本里。
脑电深度	7 个结果	深度模型“赢过”传统特征——而传统特征在那个条件下也低于抛硬币。

5.1 为什么会这样

打个比方：考试比的是两个学生的名次。如果对手因为生病考了零分，你赢了他，并不说明你考得好。

样本量小的时候，“年龄性别年级”这个对手会不稳定，有时会发挥失常到比瞎猜还差。这时任何一个平庸的模型都能“赢”它，而统计检验会一本正经地告诉你这个胜利是显著的。

5.2 我们做了什么

第一次（行为学）发现后，我们做了三项独立验证确认它是假的。最有说服力的一项是：**把孩子的诊断标签随机打乱 100 次重跑**——在完全没有真实关联的情况下，仍有约六分之一的次数能重现出同样大的“提升”。

然后给判断规则加了一条：**一个结果要被采信，它赢过的对手必须自己先站得住（高于抛硬币）。**

这条规则随后拦下了眼动的 18 个和脑电的 7 个。**如果没有它，这份报告会包含三个错误的阳性发现。**

6 我们能确定什么，不能确定什么

6.1 可以确定的

- 在**这一批孩子**身上、用**目前这套方法**，五种客观测量都不能超过年龄性别年级。
- 这个结论不是数据质量或程序错误造成的——五种数据的生理效度都独立验证过。
- 面部表情中确实存在超出“房间和长相”的真实信息，只是不足以超过人口学。
- 眼动范式中的“情绪注意偏向”指标，在当前设计下测不准。

6.2 不能由此推断的

- **不能说“心理问题没有客观生物标记”**。我们检验的是特定的几种测量、特定的分析方法、特定的一批孩子，而且其中若干条已知存在采集或设计缺陷。
- **不能说这些数据没有价值**。它们能很好地预测年龄和性别，在其他研究问题上仍然有用。
- **不能说“再多试几种方法就一定能成”**。我们已经用了从传统特征到深度学习的多种方法。

7 下一步的四个方向

1. **补齐缺失与缺陷数据**。向医院确认第三台眼动设备的数据是否存在；把赌博任务响应窗口、必可明按键采集这两个问题反馈给设备方。这是最容易做、也最可能直接带来新信息的一项。
2. **如果还有新一轮采集，修改实验设计**。情绪面孔从每种 12 张增加到 40 张以上，扫视任务从 8 个试次增加到 40 个以上，让每台设备在每所学校都采一部分。这三项改动直接针对第 3 节查出的原因。
3. **重新考虑研究问题的定义**。目前的“有 / 无心理问题”把抑郁、焦虑、高风险合并成一类，可能过于笼统。换成症状严重程度的连续评分，或某一类特定症状，客观测量可能有更好表现。建议与医院方共同讨论。
4. **把已验证的测量用于其他问题**。这些数据在年龄和性别上的预测能力很强（0.77–0.82）。发育轨迹、认知能力发展等方向可能比疾病分类更适合这批数据。

本报告为面向非技术读者的汇报版本，略去了方法细节、完整结果表和统计过程。逐项数据、方法说明与全部结果表见同目录下的技术版报告 `chongqing_progress_20260907_20260910_technical.tex` (27 页)，以及项目内的 `PROGRESS.md` 与 `reports/` 各阶段报告。本报告中的每一个数字均来自项目结果表，未作估算。